Fundamentos de Big Data y Ciencia de Datos

Tema 1. Introducción al Big Data

Índice

Esquema

Ideas clave

1.1. Introducción y objetivos

1.2. Conceptos fundamentales del Big Data

1.3. Historia y evolución del Big Data

1.4. Referencias bibliográficas

A fondo

Big Data, principles and best practices of scalable realtime data systems

Big Data: what it is and why it matters

Esquema

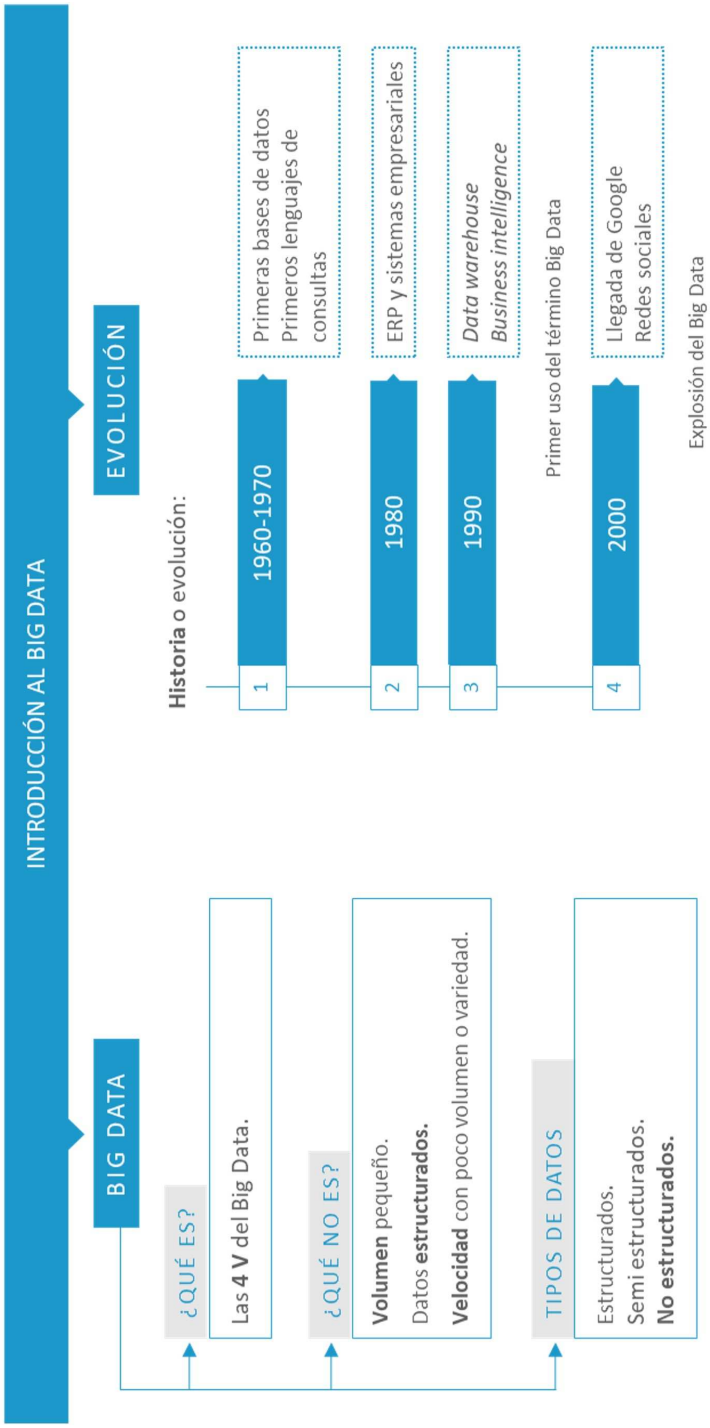

© Universidad Internacional de La Rioja (UNIR)

1.1. Introducción y objetivos

El término Big Data se refiere a **grandes volúmenes de datos** que, debido a su tamaño y complejidad, requieren tecnologías y métodos avanzados para ser procesados y analizados eficazmente. Estos datos provienen de diversas fuentes, como redes sociales, sensores, transacciones comerciales y dispositivos móviles, y se caracterizan por su alta velocidad de generación y variedad en formatos. La capacidad de gestionar y analizar estos datos ha superado las capacidades de las herramientas tradicionales de procesamiento de datos, como las bases de datos relacionales y los sistemas de *software* convencionales. Por ello, el Big Data se apoya en **nuevas tecnologías** como Hadoop, Spark y NoSQL, las cuales permiten almacenar, procesar y analizar grandes conjuntos de datos de manera eficiente (Kitchin, 2014).

L a **ciencia de datos,** por otro lado, es un campo interdisciplinario que utiliza métodos, procesos, algoritmos y sistemas científicos para extraer conocimiento y obtener conclusiones de los datos. Combina principios de estadística, informática, matemáticas y conocimiento del dominio para analizar grandes volúmenes de datos. Los científicos de datos emplean una variedad de técnicas, como minería de datos, aprendizaje automático, análisis predictivo y visualización de datos para identificar **patrones, tendencias y relaciones** en los datos que pueden informar la toma de decisiones (Provost y Fawcett, 2013).

En este sentido, los objetivos perseguidos en este tema son los siguientes:

- Proporcionar una base sólida de conocimiento sobre los conceptos fundamentales del Big Data.
- Analizar la evolución histórica de las tecnologías de la información y Big Data.

© Universidad Internacional de La Rioja (UNIR)

1.2. Conceptos fundamentales del Big Data

Big Data

En la era digital, el término Big Data ha adquirido una relevancia sin precedentes debido a la **explosión de datos** generados por diversas fuentes, como las redes sociales, los dispositivos IoT (Internet de las cosas), transacciones en línea, sensores, y muchas otras.

Big Data se refiere al **vasto volumen de datos,** que es demasiado **grande, rápido o complejo** para ser gestionado y procesado con las herramientas tradicionales de gestión de bases de datos. Este se caracteriza por las cinco V: volumen, velocidad, variedad, veracidad y valor (Deng, 2018). Además, este es relevante en diferentes industrias.

En concreto, **Big Data** se refiere a conjuntos de datos que son tan grandes, rápidos o complejos que las herramientas tradicionales de procesamiento de datos no son capaces de manejarlos de manera eficiente. Se caracteriza por las famosas 4 V (Chen, 2024):

- **Volumen:** la cantidad de datos generados y almacenados es masiva, a menudo en petabytes o incluso exabytes.
- **Velocidad:** los datos se generan y procesan a una velocidad extremadamente alta, como los datos en tiempo real provenientes de redes sociales, sensores o transacciones en línea.
- **Variedad:** los datos provienen de diferentes fuentes y pueden estar en diversos **formatos** (estructurados, no estructurados y semiestructurados). Ejemplos incluyen texto, imágenes, vídeos, sensores IoT, entre otros.
- **Valor:** los datos por sí solos no tienen valor, pero cuando se procesan y analizan pueden proporcionar información valiosa para la toma de decisiones.

© Universidad Internacional de La Rioja (UNIR)

Todas estas V son importantes cuando hablamos de Big Data, pero la que más impacto tiene es el **valor.** Todo lo que se construye con Big Data tiene que generar valor a la compañía, a los usuarios, a los clientes y a todos aquellos *stakeholders* que estén relacionados con el proyecto o iniciativa de Big Data que se esté abordando.

Se podría resumir que Big Data es un facilitador o habilitador para poder procesar y almacenar grandes conjuntos de datos con el objetivo de maximizar el valor de los datos de nuestro negocio.

En el siguiente vídeo, *Las V del Big Data,* se explican las distintas V del Big Data con ejemplos prácticos.

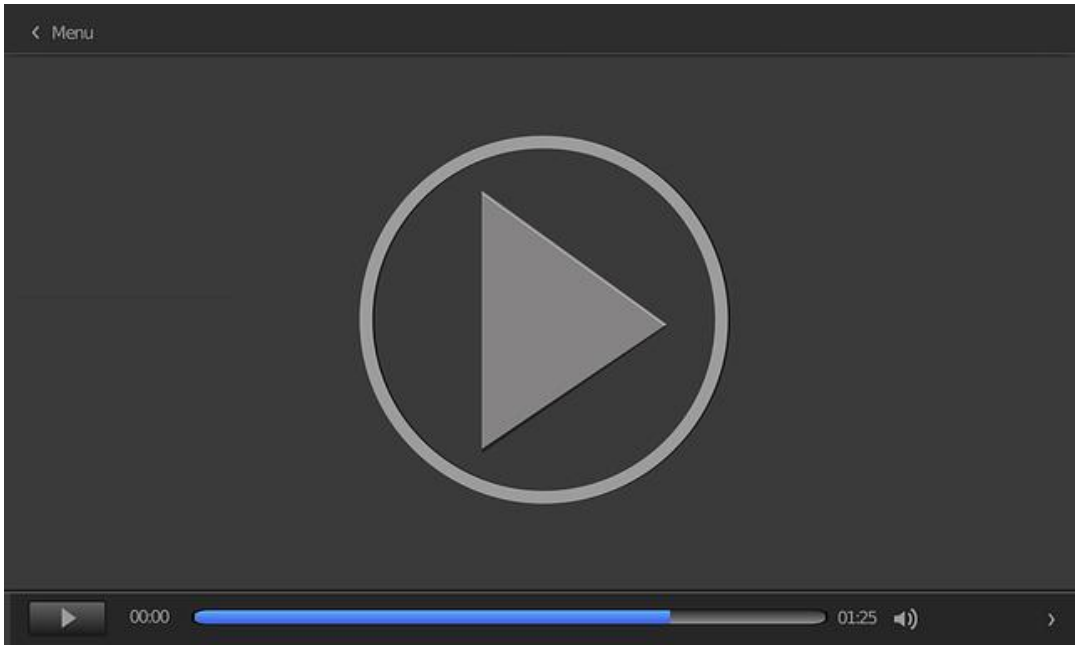

Accede al vídeo:

https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=25e99115-0659-4ca2-84e6-b22400ad3d76

© Universidad Internacional de La Rioja (UNIR)

Big Data involucra nuevas tecnologías avanzadas de almacenamiento y procesamiento, y técnicas de análisis para extraer *insights* significativos de grandes volúmenes de datos.

Figura 1. Del dato a la acción. Fuente: elaboración propia.

El reto es transformar los datos que tenemos en las compañías en información para que se pueda obtener conocimiento, a partir de éstos, con la finalidad de accionar los datos.

¿Qué no es Big Data?

Volumen pequeño o manejable

Si los datos se pueden procesar y gestionar eficientemente utilizando herramientas tradicionales (como una base de datos relacional o una hoja de cálculo), entonces no es Big Data. Por ejemplo, analizar el historial de compras de unos cientos de clientes no se considera Big Data.

Datos estructurados exclusivamente

Big Data no se refiere solo a datos estructurados que se organizan en tablas con filas y columnas. Si solo se manejan datos estructurados y en volúmenes pequeños, eso no constituye un desafío de Big Data.

© Universidad Internacional de La Rioja (UNIR)

Alta velocidad, pero bajo volumen o variedad

Si solo se trata de gestionar grandes velocidades de procesamiento sin una alta variedad o volumen de datos, tampoco sería Big Data, ya que los tres factores (volumen, velocidad y variedad) deben considerarse conjuntamente.

Tecnologías tradicionales

El uso de sistemas tradicionales, como bases de datos SQL estándar o sistemas de procesamiento de datos antiguos, no constituye Big Data, ya que no se enfrentan los desafíos que requieren soluciones más avanzadas y distribuidas.

¿Cómo de grande es el Big Data?

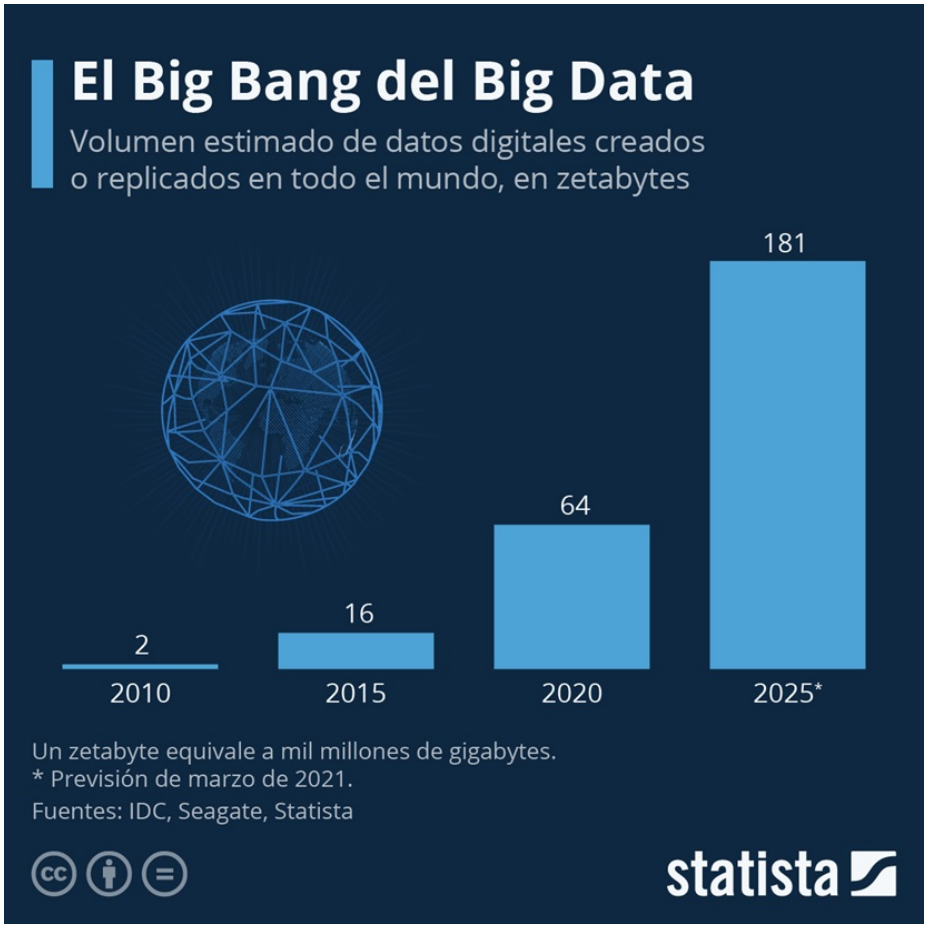

Figura 2. Volumen estimado de datos digitales creados o replicados en todo el mundo. Fuente: Mena Roa, 2021.

© Universidad Internacional de La Rioja (UNIR)

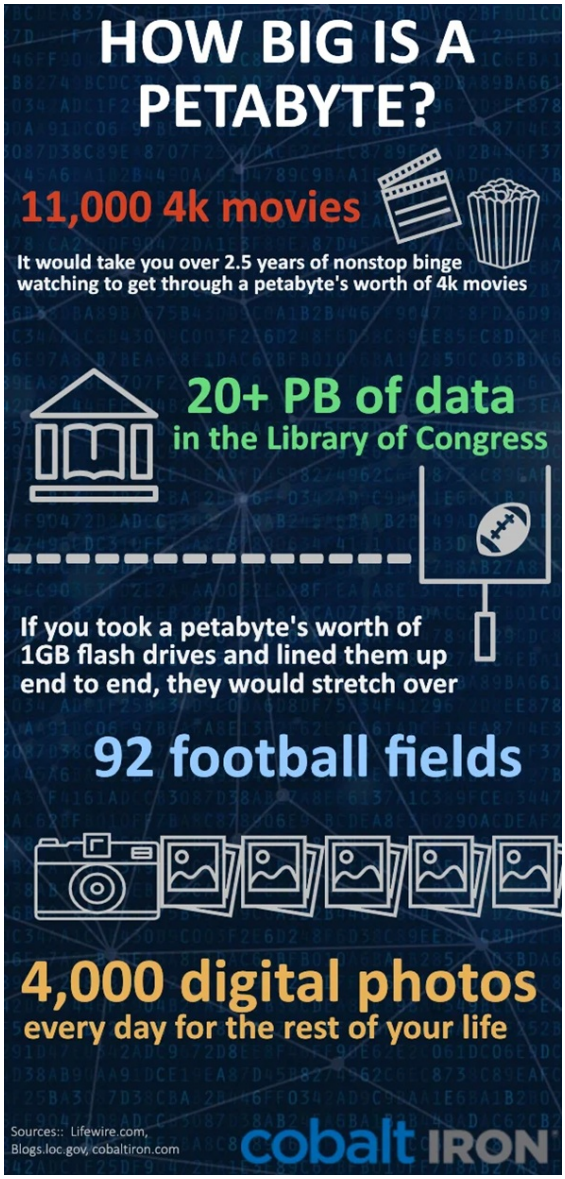

Figura 3. ¿Qué tan grande es un petabyte? Fuente: Spurlock, 2019.

© Universidad Internacional de La Rioja (UNIR)

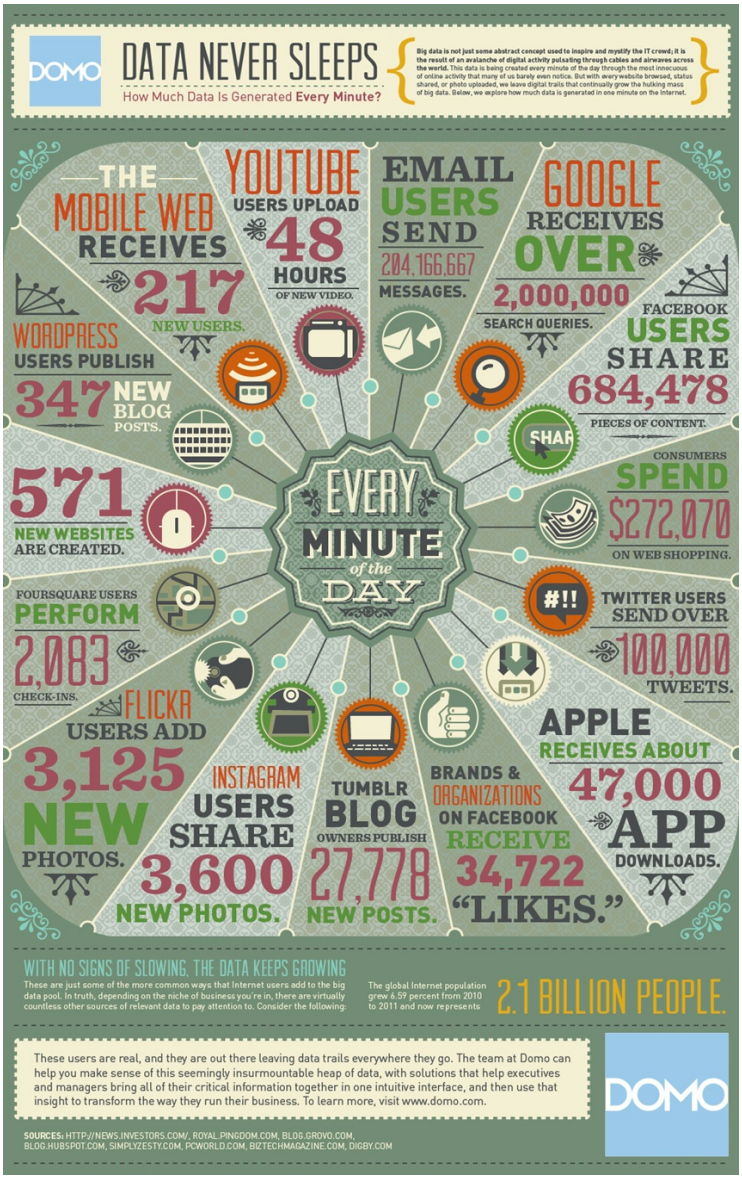

Figura 4. ¿Cuántos datos son generados por minuto? Fuente: Domo, 2013.

Data Never Sleeps es un claro ejemplo de cómo los datos crecen de manera exponencial cada minuto a nivel global. Plataformas como YouTube, Google, Facebook y Twitter generan **cantidades masivas de información** constantemente. Por ejemplo, cada minuto se suben 48 horas de vídeo en YouTube, se realizan más de dos millones de búsquedas en Google y se envían más de doscientos millones de correos electrónicos.

© Universidad Internacional de La Rioja (UNIR)

Este crecimiento acelerado es impulsado por el aumento de usuarios en Internet, las redes sociales y la proliferación de dispositivos móviles conectados. Además, plataformas como Instagram, Flickr y WordPress también contribuyen con miles de fotos y publicaciones nuevas cada minuto.

Este flujo constante de información ilustra por qué la cantidad de datos generados no solo crece en volumen, sino también en velocidad y variedad. **La generación masiva de datos es una característica fundamental del Big Data** y este crecimiento continuo resalta la necesidad de tecnologías avanzadas para capturar, almacenar y analizar todos estos datos para obtener valor a partir de ellos.

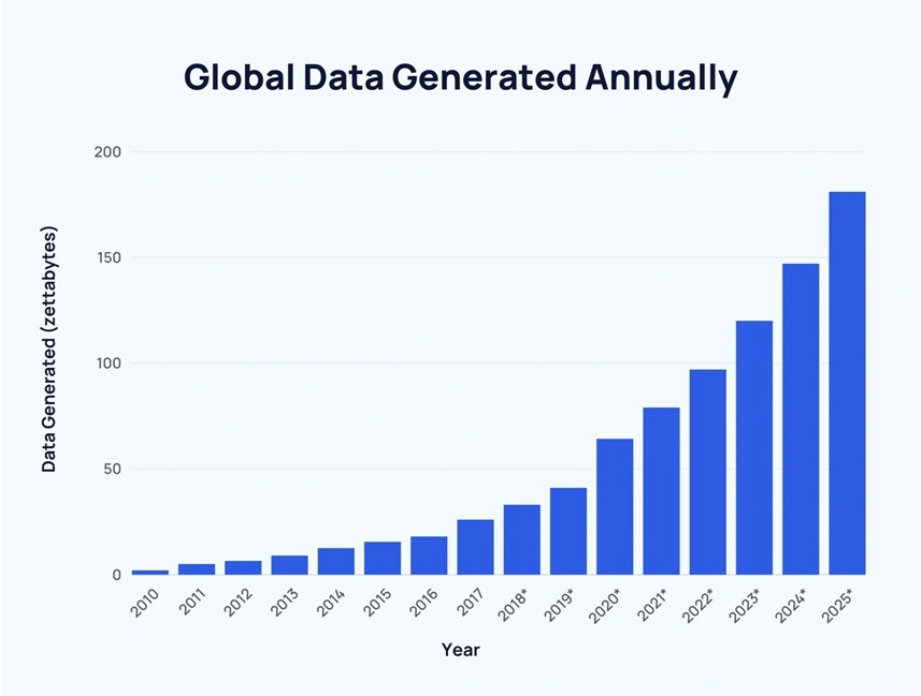

Figura 5. Datos generados globalmente de forma anual. Fuente: Duarte, 2024.

El crecimiento de los datos en los últimos años ha sido exponencial, impulsado por varios factores clave que han transformado la cantidad, velocidad y variedad de datos generados a nivel global. A continuación, se detallan las principales **razones** de este **crecimiento.**

© Universidad Internacional de La Rioja (UNIR)

Aumento de dispositivos conectados (IoT)

El **Internet de las cosas** (IoT) ha jugado un papel crucial en la expansión de los datos. Los **dispositivos conectados,** como sensores, cámaras, electrodomésticos inteligentes, vehículos autónomos, entre otros, **generan continuamente grandes volúmenes de datos en tiempo real.** Se estima que para 2025 habrá más de 75 mil millones de dispositivos conectados, todos transmitiendo datos a través de redes y plataformas.

Uso masivo de redes sociales y plataformas digitales

Las redes sociales como **Facebook, Instagram, Twitter,** y plataformas como **YouTube y TikTok** han contribuido significativamente al crecimiento de los datos. Los usuarios generan una cantidad masiva de contenido diariamente, desde publicaciones de texto hasta vídeos y fotos. Por ejemplo, cada minuto se suben 500 horas de vídeo a YouTube y se envían más de 347 000 tuits.

Incremento de smartphones y dispositivos móviles

Los smartphones son una fuente constante de datos, desde aplicaciones móviles hasta servicios de geolocalización. Estos dispositivos permiten a los usuarios generar datos continuamente, lo que incluye mensajes, transacciones, fotografías, actividad en redes sociales y datos de ubicación.

Expansión del comercio electrónico y transacciones digitales

El crecimiento del comercio electrónico y las transacciones en línea ha generado una cantidad significativa de datos. Cada compra, búsqueda de productos, reseña o interacción en línea genera información que las empresas analizan para comprender el comportamiento del consumidor, personalizar ofertas y mejorar la experiencia del usuario.

© Universidad Internacional de La Rioja (UNIR)

Crecimiento del almacenamiento en la nube

El uso de tecnologías de computación en la nube ha permitido a empresas y usuarios almacenar grandes cantidades de datos a un costo más bajo y con mayor escalabilidad. Plataformas como Amazon Web Services (AWS), Google Cloud y Microsoft Azure ofrecen soluciones de **almacenamiento masivo y análisis** que facilitan la gestión de grandes volúmenes de datos.

Avance de la digitalización en industrias tradicionales

Sectores como la salud, la manufactura, la agricultura y el transporte han adoptado tecnologías digitales para mejorar la eficiencia y tomar decisiones informadas basadas en datos. Por ejemplo, la salud genera grandes volúmenes de datos a partir de registros médicos electrónicos, imágenes de diagnóstico y dispositivos portátiles que monitorean la salud en tiempo real.

Mayor adopción de inteligencia artificial (IA) y *machine learning* (ML)

Las empresas están utilizando IA y ML para analizar y procesar grandes volúmenes de datos. Estos sistemas aprenden de los datos y requieren grandes cantidades de ellos para mejorar su precisión en tareas como la **predicción de comportamiento, detección de fraudes y optimización de procesos.**

Desarrollo de infraestructuras 5G

El despliegue de la tecnología 5G ha aumentado significativamente la **velocidad de transmisión de datos,** permitiendo que más dispositivos se conecten simultáneamente y generen datos en tiempo real. Esto facilita el intercambio rápido de grandes volúmenes de información, especialmente en sectores como la automoción autónoma, la telemedicina y las ciudades inteligentes.

© Universidad Internacional de La Rioja (UNIR)

¿Qué tipos de datos hay?

- **Estructurados:** principalmente datos tabulares que podría ser un fichero de Excel o la tabla de una base de datos.
- **Semi estructurados:** normalmente datos que requieren un tratamiento para convertir en data estructurada. Un ejemplo son los ficheros Json, que se suelen utilizar con las API en diversas redes sociales (X, Instagram, Meta, etc.)
- **No estructurados:** son datos que, como su propio nombre indica, no tienen una estructura determinada. Un ejemplo de este tipo de datos podría ser un documento de texto o una imagen.

También se puede diferenciar entre:

- **Datos visibles:** serían los datos que gestionamos en las empresas.
- **Datos oscuros** o *dark data:* corresponde al 80 % de la totalidad de los datos y son los datos que no están accesibles directamente para las compañías (IBM, 2023)

Otra posible clasificación de los datos es por su tamaño:

- *Big data.*
- *Small data:* enfocado en poder hacer análisis de los datos con un conjunto acotado de estos. Principalmente, por áreas de negocio que utilizan herramientas con capacidad de analizar menos volumen de datos (Actions Data, 2022).

© Universidad Internacional de La Rioja (UNIR)

1.3. Historia y evolución del Big Data

Desde los primeros sistemas de procesamiento por lotes en la década de 1960 hasta las modernas arquitecturas de Big Data, el **progreso tecnológico** ha sido notable, con hitos como la introducción de las **bases de datos relacionales** en la década de 1980, el auge de la **inteligencia empresarial** en la década de 1990 y la aparición de tecnologías como **Hadoop y NoSQL** en la década de 2000 (Marr, 2020).

La **evolución de las tecnologías de la información** ha sido un proceso continuo y acelerado que ha transformado la manera en que las organizaciones gestionan, analizan y utilizan los datos. Desde los primeros sistemas de procesamiento de datos en la década de 1960 hasta las complejas arquitecturas de Big Data actuales, el progreso tecnológico ha sido notable.

A lo largo de la evolución de la inteligencia empresarial o *business intelligence* (BI) a Big Data, varios hitos y avances tecnológicos han marcado el camino, transformando la capacidad de las organizaciones para procesar y analizar datos. La historia de Big Data es una evolución continua que se remonta a décadas atrás, impulsada por los avances en tecnología, la proliferación de dispositivos conectados y la explosión de datos generados por usuarios y máquinas. A continuación, se ofrece una visión general del desarrollo histórico de las tecnologías relacionadas con Big Data (Escamilla, 2022).

Décadas de 1960 y 1970, primeros avances en almacenamiento y procesamiento

Bases de datos relacionales

Durante los años 60 y 70 el almacenamiento de datos se limitaba a sistemas *mainframe* y bases de datos relacionales, como los sistemas de IBM. El modelo relacional, propuesto por Edgar Codd en 1970, estableció una estructura organizada para almacenar y recuperar grandes cantidades de datos de manera eficiente.

© Universidad Internacional de La Rioja (UNIR)

Primeros lenguajes de consulta

En 1974, IBM desarrolló **SQL** *(structured query language),* que facilitó la interacción con bases de datos relacionales.

Década de 1980, crecimiento del almacenamiento y procesamiento de datos

ERP y sistemas empresariales

En esta época, los sistemas ERP *(enterprise resource planning)* comenzaron a integrar bases de datos a nivel empresarial para gestionar datos como finanzas, ventas y fabricación, permitiendo la **centralización de la información.**

Almacenamiento de datos

Se incrementa la capacidad de almacenamiento gracias al **abaratamiento del** *hardware,* y las empresas comienzan a tener acceso a grandes volúmenes de datos internos.

Década de 1990, primeros pasos hacia el Big Data

Internet y la web

El crecimiento exponencial de la *World Wide Web* a principios de los años 90 generó un aumento masivo en la cantidad de datos generados por los usuarios. Las empresas empezaron a enfrentarse al desafío de manejar estos **grandes volúmenes de información.**

***Data warehousing* e inteligencia de negocios**

El concepto de almacenamiento de datos *(data warehousing)* y las herramientas de BI se hicieron populares, permitiendo a las empresas organizar y analizar datos históricos, aunque todavía dentro de límites manejables.

© Universidad Internacional de La Rioja (UNIR)

Primer uso del término *Big Data*

Se cree que el término Big Data fue utilizado por primera vez en los años 90, cuando se describe la cantidad masiva de datos que supera las capacidades de los sistemas tradicionales.

Años 2000, explosión del Big Data

La llegada de Google y los motores de búsqueda

Google desarrolló su motor de búsqueda a fines de los 90, introduciendo el **algoritmo PageRank** para gestionar grandes volúmenes de datos web. En 2003, Google publicó un artículo clave sobre el **Google File System** (GFS), un sistema de archivos distribuido para manejar datos masivos.

Redes sociales

El auge de plataformas como Facebook (2004), YouTube (2005) y Twitter (2006) aumentó drásticamente la generación de datos. La **información generada por los usuarios** (textos, videos, imágenes, interacciones) creó un entorno donde las empresas empezaron a necesitar tecnologías avanzadas para gestionar y analizar esta avalancha de información.

Del 2010 en adelante el Big Data se convierte en mainstream

La revolución de los datos móviles e IoT

El crecimiento de los *smartphones* y dispositivos conectados generó una cantidad exponencial de datos. Los sensores, cámaras, vehículos inteligentes y dispositivos del Internet de las cosas (IoT) añadieron nuevas fuentes de datos, creando la **necesidad de soluciones más robustas** para recopilar, almacenar y procesar esa información.

© Universidad Internacional de La Rioja (UNIR)

Aprendizaje automático e inteligencia artificial

Con la gran cantidad de datos disponibles, el campo de la inteligencia artificial (IA) y el aprendizaje automático (ML) experimentó un avance considerable. Los algoritmos comenzaron a aprovechar los datos masivos para realizar **predicciones** más precisas y obtener *insights* profundos.

Data lakes* y *cloud computing

Las empresas comenzaron a almacenar cantidades masivas de datos en *data lakes* o lagos de datos, que son **repositorios de almacenamiento** que permiten mantener los datos en su **forma nativa,** sin necesidad de estructurarlos.

L a **computación en la nube** (Amazon AWS, Google Cloud, Microsoft Azure) también jugó un papel clave al ofrecer **escalabilidad y capacidad de procesamiento** sin precedentes.

Más centrado en Big Data, la evolución sería:

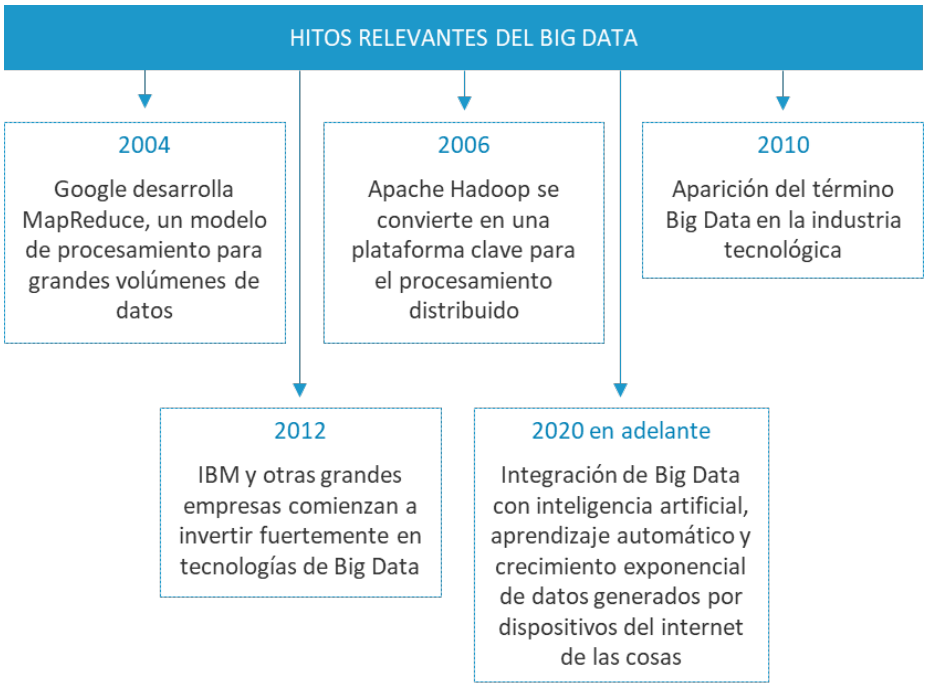

Figura 6. Hitos relevantes del Big Data. Fuente: elaboración propia.

© Universidad Internacional de La Rioja (UNIR)

Presente y futuro de Big Data

Hoy en día, el Big Data está completamente **integrado en industrias** como las finanzas, la salud, el *marketing,* el gobierno, entre otros. Las empresas utilizan el análisis de Big Data para obtener **ventajas competitivas,** como la personalización de productos, la mejora en la toma de decisiones y la optimización operativa.

Las áreas de futuro incluyen:

- *Edge computing:* procesar datos masivos en dispositivos cercanos a la fuente de datos en lugar de en grandes centros de datos centralizados.
- **Inteligencia artificial avanzada:** el desarrollo de IA y *deep learning* requiere grandes volúmenes de datos para mejorar continuamente.
- **Computación cuántica:** promete una capacidad sin precedentes para procesar datos a niveles que podrían superar las capacidades actuales.

Casos de estudio en la evolución del Big Data y la ciencia de datos

La transición del BI tradicional al Big Data ha generado numerosos casos de estudio que ilustran cómo diversas organizaciones han adoptado estas tecnologías para **mejorar sus operaciones, optimizar procesos y obtener ventajas competitivas.** A continuación, se presentan algunos casos de estudio destacados que demuestran la evolución y el **impacto** del Big Data y la ciencia de datos en diferentes sectores.

Transformación en el sector salud

- **Organización:** Kaiser Permanente.
- **Desafío:** mejorar la atención al paciente y optimizar la gestión de recursos.

© Universidad Internacional de La Rioja (UNIR)

- **Solución:** utilización de análisis predictivo y datos de registros electrónicos de salud (EHR) para identificar pacientes de alto riesgo y gestionar el flujo de pacientes y recursos en tiempo real.
- **Resultados:** reducción de tasas de readmisión, optimización de recursos y personalización de tratamientos médicos.

Optimización en el sector *retail*

- **Organización:** Walmart.
- **Desafío:** mejorar la eficiencia de la cadena de suministro y personalizar la experiencia del cliente.
- **Solución:** análisis de datos de transacciones e inventarios para predecir la demanda y personalizar ofertas y recomendaciones de productos.
- **Resultados:** reducción de costos de inventario, aumento en ventas y lealtad del cliente y optimización logística.

Innovación en el sector financiero

- **Organización:** JPMorgan Chase.
- **Desafío:** detectar y prevenir fraudes financieros.
- **Solución:** implementación de algoritmos de *machine learning* para analizar transacciones en tiempo real y evaluar riesgos crediticios.
- **Resultados:** mejora en la detección de fraudes, optimización en la gestión de riesgos crediticios y aumento en la confianza del cliente.

© Universidad Internacional de La Rioja (UNIR)

Eficiencia en el sector de transporte y logística

- **Organización:** UPS.
- **Desafío:** optimizar rutas de entrega y reducir costos operativos.
- **Solución:** uso de datos de sensores y análisis en tiempo real para optimizar rutas de entrega y mantenimiento predictivo.
- **Resultados:** reducción de costos de combustible, mejora en tiempos de entrega y eficiencia operativa.

Innovación en el sector de energía

- **Organización:** General Electric (GE).
- **Desafío:** mejorar la eficiencia y la fiabilidad de las operaciones de generación y distribución de energía.
- **Solución:** análisis de datos de sensores en infraestructuras energéticas y mantenimiento predictivo.
- **Resultados:** incremento en eficiencia operativa, reducción de costos de mantenimiento y mejora en la fiabilidad y sostenibilidad de las operaciones.

© Universidad Internacional de La Rioja (UNIR)

1.4. Referencias bibliográficas

Actions Data. (2022, marzo 25). *Big data vs Small data: principales diferencias y características.* Actions. https://actions.es/big-data-vs-small-data-principales-diferencias-y-caracteristicas/

Chen, M. (2024, septiembre 23). *¿Qué es el big data?* Oracle. https://www.oracle.com/co/big-data/what-is-big-data/

Deng, L. (2018). Artificial Intelligence in the Rising Wave of Deep Learning: The Historical Path and Future Outlook [Perspectives]. *IEEE Signal Processing Magazine, 35:* p. 180-177. https://doi.org/10.1109/MSP.2017.2762725

Domo. (2013). *Data Never Sleeps* [Infografía]. https://www.domo.com/learn/infographic/infographic-data-never-sleeps

Duarte, F. (2024, junio 13). *Amount of Data Created Daily (2024).* Exploding topics. https://explodingtopics.com/blog/data-generated-per-day

Escamilla, J. (2022, mayo 4). *Los orígenes del Big Data.* MR Informática. https://mrinformatica.es/los-origenes-del-big-data/

IBM. (2023, octubre 2). *What is dark data?* https://www.ibm.com/think/topics/dark-data

Kitchin, R. (2014). *The data revolution: Big Data, open data, data infrastructures and their consequences.* Sage.

Marr, B. (2020). *The intelligence revolution: transforming your business with AI.* Kogan Page.

© Universidad Internacional de La Rioja (UNIR)

Mena Roa, M. (2021, octubre 22). *El Big Bang del Big Data.* Statista. https://es.statista.com/grafico/26031/volumen-estimado-de-datos-digitales-creados-o-replicados-en-todo-el-mundo/

Provost, F. y Fawcett, T. (2013). *Data Science for business: what you need to know about data mining and data-analytic thinking.* O'Reilly Media, Inc.

Spurlock, R. (2019, octubre 31). *Petabyte - How Much Information Could it Actually Hold?* [Infografía]. Cobalt Iron. https://info.cobaltiron.com/blog/petabyte-how-much-information-could-it-actually-hold

© Universidad Internacional de La Rioja (UNIR)

Big Data, principles and best practices of scalable realtime data systems

Marz, N. y Warren, J. (2015). *Big Data: principles and best practices of scalable real-time data systems.* Manning.

Este libro proporciona una comprensión profunda de los principios del Big Data y cómo construir sistemas escalables para el procesamiento de datos en tiempo real. Es una excelente referencia para profundizar en la arquitectura de sistemas de Big Data, el diseño de *pipelines* de datos y las mejores prácticas para la implementación de soluciones de datos a gran escala.

© Universidad Internacional de La Rioja (UNIR)

Big Data: what it is and why it matters

SAS. (s. f.). *Big Data: what it is and why it matters.* https://www.sas.com/en_us/insights/big-data/what-is-big-data.html#:~:text=Big%20data%20is%20a%20term,with%20the%20data%20that%20matters

Este artículo proporciona una explicación detallada de qué es el Big Data, cómo se diferencia de los datos tradicionales, las tecnologías utilizadas y sus aplicaciones en diversos sectores. Es un excelente recurso para entender los conceptos fundamentales y el impacto del Big Data en la ciencia de datos.

© Universidad Internacional de La Rioja (UNIR)