Fundamentos de Big Data y Ciencia de Datos

Tema 4. Perfiles profesionales y metodologías en proyectos de Big Data y ciencia de datos

Índice

Esquema

Ideas clave

4.1. Introducción y objetivos

4.2. Roles de Big Data y ciencia de datos

4.3. Metodologías en proyectos de datos

4.4. Referencias bibliográficas

A fondo

Rol del analista de datos

CRISP-DM, metodología para proyectos de ciencia y minería de datos

Esquema

PERFILES Y METODOLOGÍAS EN PROYECTOS DE BIG DATA Y CIENCIA DE DATOS

ROLES PRINCIPALES

Director de ciencia de datos o *chief data officer* (CDO)

Director de datos, estrategia y gobierno

Científico de datos o *data scientist*

Análisis avanzado de los datos para la toma de decisiones

Analista de datos o *data analyst*

Tratamiento de los datos para generar *insights*

Ingeniero de datos o *data engineer*

Captura y preparación de los datos para su posterior análisis

Analista de negocio o *business analyst*

Tratamiento de datos con conocimiento avanzado del negocio

METODOLOGÍAS

KDD

Primeros enfoques formales para el análisis de datos y la minería de datos

CRISP-DM

Metodología popular y ampliamente utilizada en proyectos de ciencia de datos y Big Data

SEMMA

Se utiliza para guiar el proceso de minería de datos, especialmente en proyectos donde se utilizan herramientas de SAS

Agile Data Science

Metodología Agile originada en el desarrollo de software, ha sido adaptada para proyectos de Ciencia de Datos y Big Data

Lean Analytics

Metodología derivada de Lean Startup que se enfoca en construir soluciones basadas en datos de forma rápida y eficiente

Six Sigma en Big Data

Metodología orientada a mejorar la calidad y reducir errores en los procesos empresariales

© Universidad Internacional de La Rioja (UNIR)

4.1. Introducción y objetivos

En la era del Big Data y la ciencia de datos, las organizaciones enfrentan el desafío de gestionar y analizar grandes volúmenes de datos para obtener información valiosa que impulse la toma de decisiones estratégicas. Para abordar estos desafíos, han surgido nuevos **perfiles profesionales** especializados en la recolección, procesamiento, análisis y uso de datos. Estos profesionales incluyen científicos de datos, ingenieros de datos, analistas, arquitectos de Big Data, entre otros, cada uno con funciones específicas dentro del ciclo de vida del proyecto.

Además de contar con un **equipo multidisciplinario,** es crucial la implementación de metodologías de trabajo eficientes que aseguren que los proyectos de Big Data y ciencia de datos se lleven a cabo de manera estructurada y ágil. **Metodologías** como **CRISP-DM** *(cross industry standard process for data mining),* **Agile** y el enfoque **Lean Analytics** son ampliamente utilizadas en la industria para organizar y gestionar estos proyectos, desde la definición del problema hasta la implementación y monitoreo de las soluciones.

Este tema explora los roles profesionales clave en los proyectos de Big Data y ciencia de datos, y las metodologías que aseguran la entrega exitosa de resultados en entornos empresariales dinámicos y complejos con los siguientes objetivos:

- Identificar los **principales perfiles profesionales** involucrados en proyectos de Big Data y ciencia de datos, comprendiendo sus responsabilidades y habilidades clave.
- Entender las **metodologías más utilizadas** en la gestión y desarrollo de proyectos de datos, incluyendo CRISP-DM, Agile y Lean Analytics, y su aplicación práctica en distintos escenarios.

© Universidad Internacional de La Rioja (UNIR)

4.2. Roles de Big Data y ciencia de datos

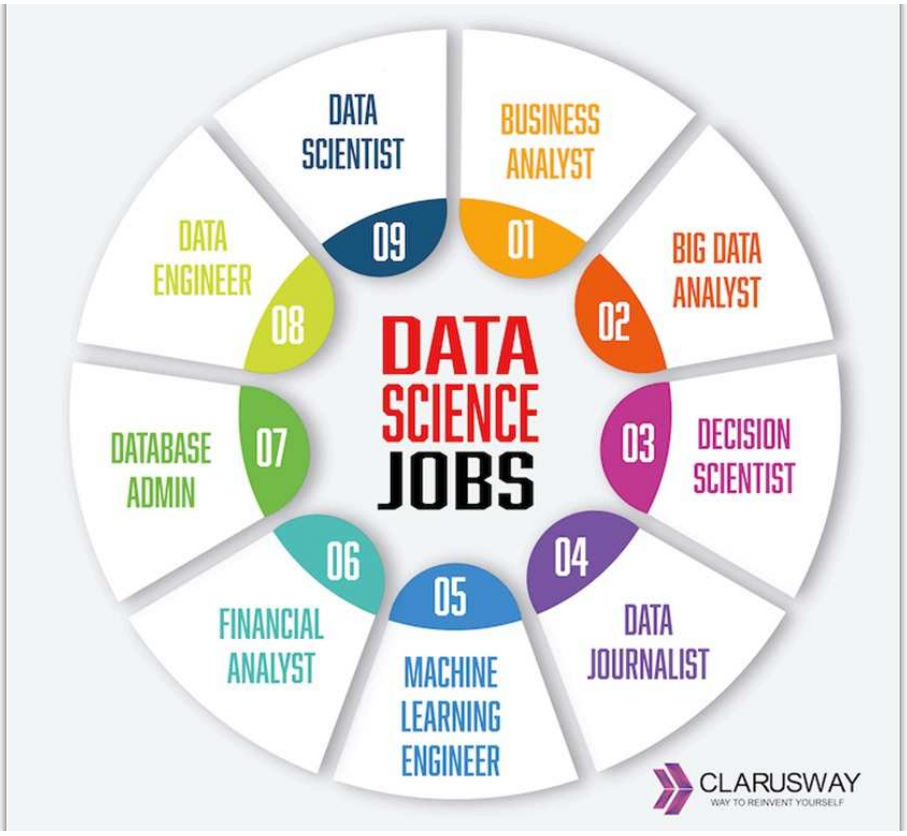

Figura 1. Trabajos involucrados en la ciencia de datos. Fuente: Yildiz, 2021.

Científico de datos o data scientist

Descripción

El científico de datos es uno de los roles más completos y demandados. Su función e s **explorar, analizar y modelar datos** para identificar patrones, tendencias y relaciones útiles. Utiliza técnicas avanzadas como el *machine learning,* la minería de datos, el análisis predictivo y la estadística. Su trabajo es **generar modelos** que aporten i*nsights* accionables que ayuden a las organizaciones a tomar decisiones estratégicas.

© Universidad Internacional de La Rioja (UNIR)

Habilidades

- Conocimiento profundo de **estadística y matemáticas.**
- Competencia en *machine learning,* **algoritmos predictivos y técnicas de análisis avanzado.**
- Dominio de lenguajes de programación como **Python, R** y herramientas como **TensorFlow y Scikit-learn.**
- Habilidad para interpretar datos y comunicar resultados complejos de manera comprensible para *stakeholders* no técnicos.

Ingeniero de datos o data engineer

Descripción

El ingeniero de datos es responsable de diseñar, construir y mantener la infraestructura necesaria para gestionar grandes volúmenes de datos. Su trabajo consiste en **preparar los datos** para su análisis y asegurar que el *pipeline* de datos (ingesta, procesamiento y almacenamiento) funcione de manera eficiente y escalable. Esto incluye la implementación de **soluciones de almacenamiento y el desarrollo de sistemas de procesamiento** *batch* y *streaming.*

Habilidades

- Conocimiento en **arquitecturas de Big Data** y procesamiento distribuido (Hadoop, Spark).
- Experiencia con **bases de datos relacionales y no relacionales** (SQL, NoSQL).
- Habilidades en programación con lenguajes como **Python, Java y Scala.**
- Familiaridad con herramientas de **ETL** *(extract, transform, load)* y sistemas de mensajería como **Kafka.**

© Universidad Internacional de La Rioja (UNIR)

Analista de datos o data analyst

Descripción

El analista de datos tiene como responsabilidad principal **examinar conjuntos de datos para generar informes,** visualizar datos y presentar *insights* que ayuden en la toma de decisiones empresariales. A menudo, se encargan de trabajar con datos estructurados y crear *dashboards* y reportes visuales usando herramientas de BI *(business intelligence).*

Habilidades

- Experiencia en **herramientas de visualización de datos** como **Tableau, Power BI, o Google Data Studio.**
- Conocimientos en **SQL** para la manipulación y consulta de bases de datos.
- Habilidades analíticas y capacidad para interpretar tendencias y patrones en los datos.
- Comunicación efectiva para presentar *insights* a partes interesadas.

Analista de negocio o business analyst

Descripción

E l *business analyst* (BA) desempeña un papel crucial al actuar como el **vínculo entre el equipo técnico y el negocio.** Su principal responsabilidad es garantizar que los proyectos de análisis de datos estén **alineados con los objetivos estratégicos** de la organización y que las soluciones propuestas aporten valor tangible.

© Universidad Internacional de La Rioja (UNIR)

Habilidades

- **Conocimiento del negocio:** es fundamental que el BA tenga un profundo entendimiento del sector y del negocio para identificar cómo los datos pueden generar valor.
- **Capacidad analítica:** aunque no necesariamente debe ser un experto en análisis de datos, el BA debe entender los conceptos de Big Data y las metodologías de análisis para colaborar eficazmente con los equipos técnicos.
- **Comunicación efectiva:** debe ser capaz de transmitir ideas complejas de manera clara y comprensible tanto a equipos técnicos como a *stakeholders* no técnicos.
- **Orientación a resultados:** su trabajo está enfocado en garantizar que el análisis de Big Data tenga un impacto medible y directo en los objetivos del negocio.

Especialista en visualización de datos o data visualization specialist

Descripción

El especialista en visualización de datos se enfoca en presentar los datos de manera visualmente atractiva y comprensible para usuarios técnicos y no técnicos. Su objetivo es hacer que los **datos** sean **accesibles y útiles,** a través de *dashboards* interactivos, gráficos y otros métodos de visualización.

Habilidades

- Dominio de herramientas de **visualización de datos** como **Tableau, Power BI o D3.js.**
- Habilidades de **diseño gráfico** y comprensión de principios de UX/UI.

© Universidad Internacional de La Rioja (UNIR)

- Habilidad para interpretar datos complejos y presentarlos de manera sencilla.
- Conocimiento básico de **estadística** y análisis de datos para interpretar los resultados correctamente.

Ingeniero de aprendizaje automático o machine learning engineer

Descripción

El ingeniero de aprendizaje automático diseña, implementa y optimiza modelos de *machine learning* que **automatizan procesos y generan predicciones basadas en datos.** Su trabajo implica transformar los modelos de los científicos de datos en sistemas productivos que pueden escalar, actualizarse y mantenerse en tiempo real.

Habilidades

- Profundo conocimiento en **algoritmos** de *machine learning* y *deep learning.*
- Competencia en programación con lenguajes como **Python, Java o C++.**
- Familiaridad con *frameworks* de *machine learning* como **TensorFlow, Keras, y PyTorch.**
- Conocimiento en arquitecturas de **procesamiento distribuido** y manejo de grandes volúmenes de datos.

Administrador de bases de datos o database administrator (DBA)

Descripción

El administrador de bases de datos es responsable de la **gestión y mantenimiento de las bases de datos,** asegurando que estén disponibles, seguras y funcionando de manera eficiente. Aunque su papel se ha transformado con el auge del Big Data, sigue siendo crucial en la gestión de datos estructurados y semiestructurados.

© Universidad Internacional de La Rioja (UNIR)

Habilidades

- Experiencia con **bases de datos relacionales** (SQL, MySQL, PostgreSQL) **y NoSQL** (MongoDB, Cassandra).
- Administración de **seguridad y copias de seguridad** de los datos.
- Optimización del rendimiento de consultas y gestión de permisos de usuarios.

Arquitecto de Big Data

Descripción

El arquitecto de Big Data diseña la infraestructura y la arquitectura de sistemas de datos a gran escala. Su rol es asegurar que las **soluciones** de Big Data sean **escalables, seguras** y capaces de procesar datos masivos. También selecciona las tecnologías adecuadas para implementar estas soluciones, como **sistemas de almacenamiento y procesamiento distribuido.**

Habilidades

- Conocimiento en **arquitecturas distribuidas** y sistemas como **Hadoop, Spark, y Kafka.**
- Capacidad para diseñar soluciones escalables para la **ingesta,** almacenamiento y procesamiento de datos.
- Experiencia en plataformas de **computación en la nube** como **AWS, Azure, y Google Cloud.**
- Comprensión de las necesidades empresariales para alinear la infraestructura con los objetivos del negocio.

© Universidad Internacional de La Rioja (UNIR)

Traductor de datos o data translator

Descripción

El traductor de datos es un rol clave en los proyectos de Big Data, cuya función principal es servir como **puente** entre los equipos **técnicos** (científicos de datos, ingenieros de datos y analistas de datos) y las **áreas de negocio.** Este rol es fundamental para asegurar que los análisis y **datos generados sean comprensibles y útiles para la toma de decisiones** empresariales.

Habilidades

- Comprender el **lenguaje del negocio y de los datos.**
- Identificación de **oportunidades de negocio.**
- Interpretación y comunicación de *insights.*
- Facilitar la **colaboración entre equipos** de datos y las áreas funcionales de la empresa.

Director de ciencia de datos o chief data officer (CDO)

Descripción

El director de ciencia de datos es el responsable ejecutivo de la **estrategia de datos** de una organización. Su rol es asegurar que los datos se gestionan adecuadamente y que los recursos de datos sean utilizados para generar valor. Es un rol estratégico que integra los datos en la toma de decisiones de alto nivel.

Habilidades

- Habilidades de **liderazgo y gestión estratégica** de datos.
- Capacidad para alinear los objetivos de la organización con la **estrategia de datos.**

© Universidad Internacional de La Rioja (UNIR)

- Comprensión profunda de tecnologías de Big Data y **ciencia de datos.**
- Conocimiento sobre **gobernanza de datos y cumplimiento normativo** (como el Reglamento General de Protección de Datos).

En el siguiente vídeo, *Roles de datos no técnicos,* se verán los distintos roles en el ámbito del Big Data y de la ciencia de datos, profundizando en los roles no técnicos.

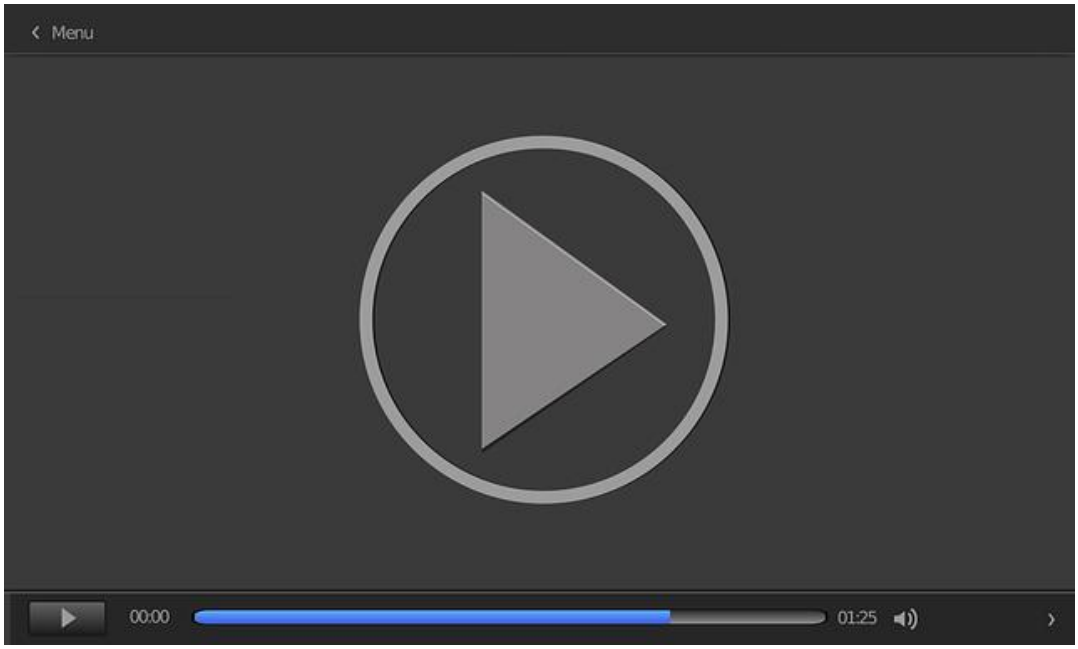

Accede al vídeo:

https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=4565a27e-7cc4-4623-91f5-b23301001f32

© Universidad Internacional de La Rioja (UNIR)

4.3. Metodologías en proyectos de datos

Knowledge discovery in databases (KDD)

El proceso de **KDD** es uno de los primeros enfoques formales para el análisis de datos y la minería de datos. Es un marco general utilizado para extraer conocimiento útil a partir de grandes conjuntos de datos (Fayyad *et al.,* 1996).

Fases

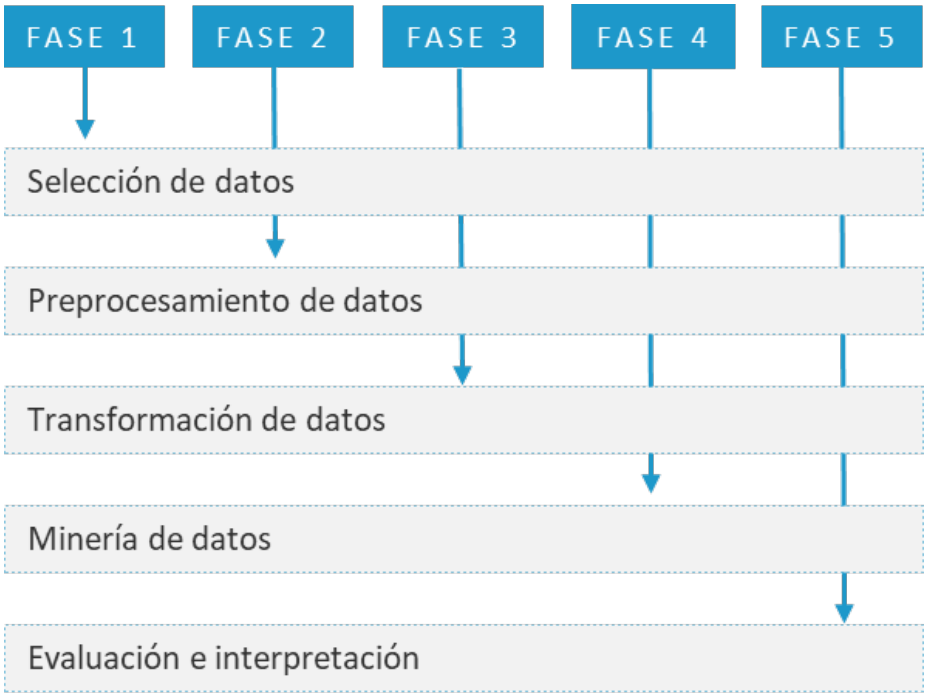

Figura 2. Fases del proceso KDD. Fuente: elaboración propia.

- **Selección de datos:** se seleccionan los datos relevantes para el análisis desde las bases de datos.
- **Preprocesamiento de datos:** limpieza y preparación de los datos para eliminar ruido, valores faltantes o inconsistencias.

© Universidad Internacional de La Rioja (UNIR)

- **Transformación de datos:** adapta los datos a formatos adecuados para el análisis mediante procesos de normalización, reducción de dimensiones o creación de nuevas variables.
- **Minería de datos:** aplicación de técnicas de análisis y algoritmos para identificar patrones y relaciones.
- **Evaluación e interpretación:** se evalúan los resultados obtenidos para identificar patrones válidos y significativos, y se interpretan en el contexto del negocio.

Ventajas

- Amplio enfoque en todo el ciclo de vida del análisis de datos, no solo en la minería de datos.
- Se centra en la transformación y preparación de datos, lo que lo hace adecuado para proyectos con grandes volúmenes de datos no estructurados.

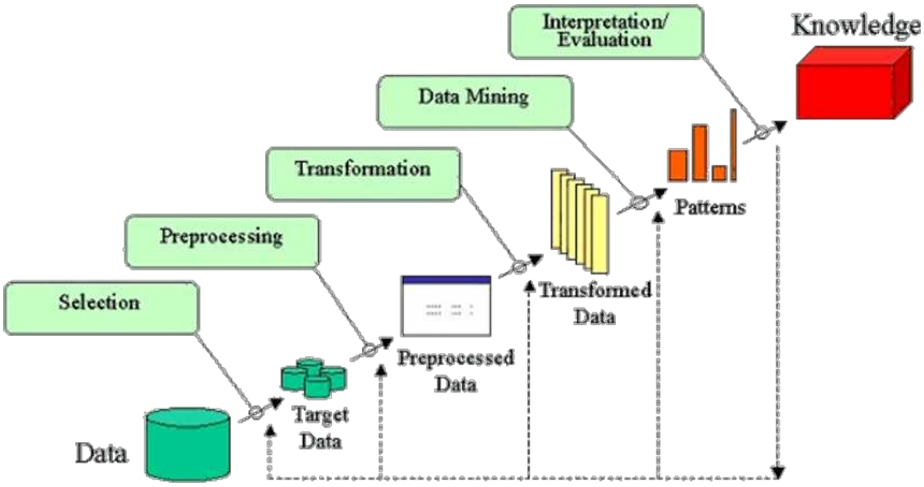

Figura 3. Otra perspectiva del proceso KDD. Fuente: Fayyad *et al.,* 1996.

© Universidad Internacional de La Rioja (UNIR)

Cross industry standard process for data mining (CRISP-DM)

CRISP-DM es una de las metodologías más populares y ampliamente utilizadas en proyectos de ciencia de datos y Big Data. Fue desarrollada en los años 90 y sigue siendo un **enfoque estándar** debido a su flexibilidad y aplicabilidad en diferentes industrias (Chapman *et al.,* 2000).

Figura 4. Metodología de Datos CRISP-DM. Fuente: IPMOGuide, s. f.

© Universidad Internacional de La Rioja (UNIR)

Fases

- **Entendimiento** del negocio: se identifican los objetivos del proyecto desde una perspectiva empresarial y se traduce en un problema de datos.
- **Objetivos del negocio:** entender a fondo lo que el cliente quiere lograr desde una perspectiva empresarial.
- **Evaluación** de la situación: determinar los recursos disponibles, requisitos del proyecto, riesgos y contingencias.
- **Objetivos de la minería de datos:** definir qué se espera lograr desde una perspectiva técnica.
- **Plan del proyecto:** seleccionar tecnologías y herramientas, y definir planes detallados para cada fase del proyecto.
- **Entendimiento de los datos:** se recopilan y analizan los datos disponibles para comprender su estructura, calidad y potencial para resolver el problema:
- **Recolección de los datos iniciales:** adquirir los datos necesarios y cargarlos en la herramienta de análisis.
- **Descripciónde los datos:** examinar y documentar las propiedades superficiales de los datos.
- **Exploración** de los datos: profundizar en los datos, visualizarlos e identificar relaciones.
- Verificación de la **calidad** de los datos: evaluar la limpieza de los datos y documentar cualquier problema de calidad
- **Preparación** de los datos: se limpian, transforman y estructuran los datos para que puedan ser utilizados en modelos analíticos.
- **Selección** de datos: determinar qué conjuntos de datos se utilizarán.

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

- **Limpieza** de datos: corregir, imputar o eliminar valores erróneos.
- **Construcción** de datos: derivar nuevos atributos útiles.
- **Integración** de datos: combinar datos de múltiples fuentes.
- **Formateo** de datos: dar formato a los datos para que sean adecuados para el modelado.
- **Modelado:** se seleccionan y aplican los algoritmos de *machine learning* o análisis de datos para generar modelos predictivos o descriptivos.
- **Selección de técnicas** de modelado: elegir las técnicas de modelado adecuadas.
- Generación de un **diseño de prueba:** crear un plan para probar la calidad y validez del modelo.
- **Construcción del modelo:** aplicar las técnicas de modelado a los datos preparados.
- **Evaluación del modelo**: evaluar el modelo para asegurarse de que cumple con los objetivos del negocio
- **Evaluación:** se evalúan los resultados del modelo para asegurarse de que cumplen con los objetivos empresariales.
- Evaluación de **resultados:** comparar los resultados del modelo con los criterios de éxito definidos.
- **Revisión del proceso:** revisar todo el proceso para identificar cualquier problema o área de mejora.
- Determinación de los **próximos pasos:** decidir si el modelo está listo para ser desplegado o si se necesitan ajustes adicionales.

© Universidad Internacional de La Rioja (UNIR)

- **Despliegue:** los modelos y resultados se implementan en la infraestructura de la organización para su uso en la toma de decisiones.
- **Planificación del despliegue:** preparar un plan detallado para la implementación del modelo.
- **Monitoreo y mantenimiento:** supervisar el modelo en producción y realizar ajustes según sea necesario.
- **Revisión del proyecto:** evaluar el proyecto en su totalidad y documentar las lecciones aprendidas.

Ventajas

- Proceso iterativo y adaptable.
- Aplicable en una variedad de sectores y tipos de datos.
- Proporciona una estructura clara y comprensible para el desarrollo de proyectos.

Vamos a ver un **ejemplo práctico** de cómo se aplica la metodología CRISP-DM en un proyecto real. Imaginemos que una empresa de *retail* quiere mejorar sus estrategias de *marketing* mediante el análisis de datos de ventas y comportamiento de los clientes. Aquí te explico cómo se podría aplicar cada fase de CRISP-DM (Galán, 2015).

Comprensión del negocio

- Objetivos del negocio: la empresa quiere aumentar las ventas y mejorar la fidelización de los clientes.
- Evaluación de la situación: se revisan los recursos disponibles, como los datos históricos de ventas, datos demográficos de los clientes y herramientas de análisis.

© Universidad Internacional de La Rioja (UNIR)

- Objetivos de minería de datos: identificar patrones de compra y segmentar a los clientes en grupos específicos para campañas de *marketing* dirigidas.
- Plan del proyecto: definir un cronograma y asignar roles y responsabilidades.

Comprensión de los datos

- Recolección de datos iniciales: se recopilan datos de ventas, datos de clientes y datos de interacción en línea.
- Descripción de los datos: se analizan las características básicas de los datos, como la distribución de las ventas por región y por producto.
- Exploración de los datos: se utilizan herramientas de visualización para identificar tendencias y anomalías.
- Verificación de la calidad de los datos: se detectan y corrigen errores en los datos, como valores faltantes o duplicados.

Preparación de los datos

- Selección de datos: se eligen los datos más relevantes para el análisis, como las transacciones de los últimos dos años.
- Limpieza de datos: se eliminan registros incompletos y se corrigen errores.
- Construcción de datos: se crean nuevas variables, como la frecuencia de compra y el valor promedio de las transacciones.
- Integración de datos: se combinan datos de diferentes fuentes, como ventas en tienda y ventas en línea.
- Formateo de datos: se transforman los datos en un formato adecuado para el modelado.

© Universidad Internacional de La Rioja (UNIR)

Modelado

- Selección de técnicas de modelado: se eligen técnicas como el *clustering* para segmentar a los clientes y regresión para predecir ventas futuras.
- Generación de un diseño de prueba: se divide el conjunto de datos en datos de entrenamiento y datos de prueba.
- Construcción del modelo: se entrenan los modelos con los datos de entrenamiento.
- Evaluación del modelo: se evalúa la precisión y la validez de los modelos utilizando los datos de prueba.

Evaluación

- Evaluación de resultados: se comparan los resultados del modelo con los objetivos de negocio para asegurarse de que sean útiles.
- Revisión del proceso: se revisa todo el proceso para identificar posibles mejoras.
- Determinación de los próximos pasos: se decide si el modelo está listo para ser desplegado o si se necesitan ajustes adicionales.

Despliegue

- Planificación del despliegue: se prepara un plan detallado para implementar el modelo en el entorno de producción.
- Monitoreo y mantenimiento: se supervisa el rendimiento del modelo y se realizan ajustes según sea necesario.
- Revisión del proyecto: se evalúa el proyecto en su totalidad y se documentan las lecciones aprendidas.

© Universidad Internacional de La Rioja (UNIR)

SEMMA (sample, explore, modify, model, assess)

Desarrollada por **SAS Institute, SEMMA** es una metodología que se utiliza para guiar el proceso de minería de datos, especialmente en proyectos donde se utilizan herramientas de SAS. Similar a CRISP-DM, SEMMA se enfoca en proporcionar una **estructura clara** para la extracción de conocimiento a partir de los **datos** (Data Science PM, 2024).

Fases

- *Sample* o **muestrear:** se extrae una muestra representativa de los datos disponibles para reducir la complejidad y facilitar la gestión.
- *Explore* o **explorar:** se exploran los datos a través de análisis estadísticos y visualización de datos para descubrir relaciones y patrones.
- *Modify* o **modificar:** se transforman los datos, creando nuevas variables o ajustando los datos existentes para mejorar el análisis.
- *Model* o **modelar:** se aplican algoritmos de minería de datos o *machine learning* para crear modelos predictivos o descriptivos.
- *Assess* o **evaluar:** se evalúan los resultados del modelo para determinar su precisión, efectividad y adecuación a los objetivos del negocio.

Ventajas

- Centrada en el desarrollo de modelos predictivos y descriptivos.
- Bien estructurada para el uso de herramientas específicas de SAS.
- Enfoque claro en la evaluación del modelo y la toma de decisiones basada en datos.

© Universidad Internacional de La Rioja (UNIR)

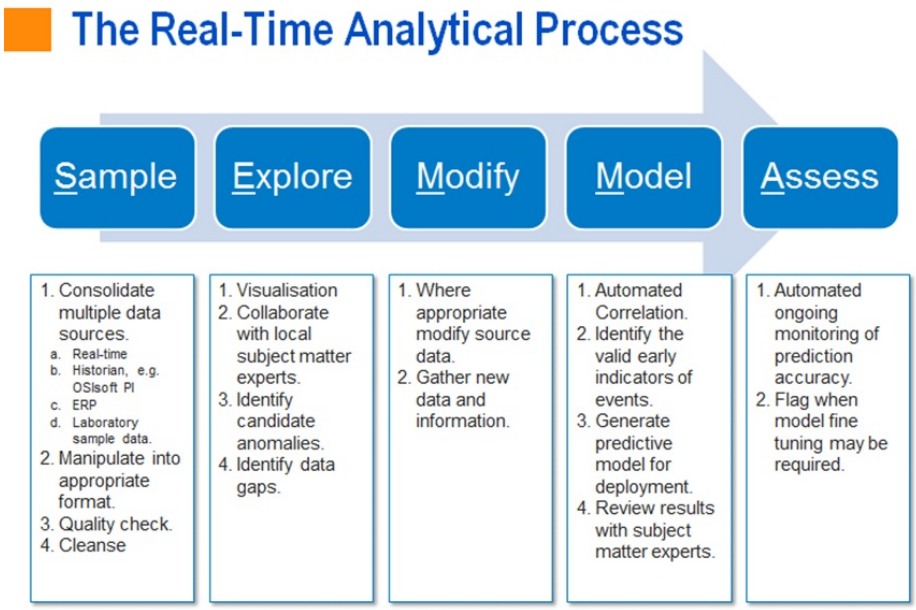

Figura 5. Proceso de SEMMA para generar conocimiento a partir de datos crudos. Fuente: Holdway, 2012.

Agile Data Science

La **metodología Agile,** originada en el desarrollo de *software* ha sido adaptada para proyectos de ciencia de datos y Big Data. Esta metodología permite a los equipos ser más flexibles y reaccionar rápidamente a los cambios **durante el ciclo de vida del proyecto** (Jurney, 2017).

Características

- **Iteraciones cortas:** se trabaja en ciclos cortos, generalmente de dos a cuatro semanas, llamados *sprints,* lo que permite la revisión continua del progreso y ajustes en los objetivos.
- **Colaboración constante:** los equipos trabajan en colaboración con *stakeholders* y usuarios finales para garantizar que las soluciones estén alineadas con los objetivos del negocio.
- **Mejora continua:** después de cada *sprint,* se revisan los resultados y se realizan ajustes basados en los aprendizajes y el *feedback.*

© Universidad Internacional de La Rioja (UNIR)

Ventajas de Agile en la ciencia de datos

- Flexibilidad para adaptarse a cambios en los datos o en los requisitos del negocio.
- Entrega continua de valor en forma de incrementos de datos o modelos funcionales.
- Fomenta la colaboración entre los científicos de datos y otras áreas funcionales.

KANBAN para la ciencia de datos

KANBAN es otra metodología ágil que se ha adaptado para la **ciencia de datos y Big Data.** Se enfoca en visualizar el flujo de trabajo para gestionar y mejorar la eficiencia del equipo en proyectos complejos (Data Science PM, 2025).

Principios

- **Visualización del trabajo:** utiliza un tablero donde se representa cada tarea, lo que permite a los equipos ver de forma clara en qué fase está cada tarea o proyecto.
- **Límite de trabajo en proceso:** se establece un límite en la cantidad de tareas que pueden estar en proceso a la vez, lo que ayuda a mejorar el enfoque y la eficiencia.
- **Flujo continuo:** el objetivo es tener un flujo de trabajo continuo y sin interrupciones, desde la idea hasta la implementación.

Ventajas

- Proporciona visibilidad y transparencia en el flujo de trabajo.
- Facilita la priorización y gestión de tareas en proyectos de Big Data, que a menudo implican múltiples dependencias.
- Fomenta la mejora continua, ya que se identifican cuellos de botella y oportunidades de optimización.

© Universidad Internacional de La Rioja (UNIR)

DataOps o data operations

DataOps es una metodología moderna inspirada en **DevOps,** adaptada para gestionar proyectos de datos. Se centra en mejorar la colaboración entre equipos de datos y automatizar los procesos de integración, entrega y monitoreo de datos, garantizando **calidad y eficiencia a lo largo del ciclo de vida del proyecto** (Palmer, 2019).

Características

- **Automatización de procesos de datos:** desde la ingestión hasta el procesamiento y el despliegue, DataOps introduce automatización en la infraestructura de datos.
- **Integración y despliegue continuos (CI/CD):** permite a los equipos desarrollar, probar y desplegar modelos de datos y pipelines de manera rápida y fiable.
- **Monitoreo continuo:** se supervisan los datos y los modelos en producción para asegurar que sigan ofreciendo resultados precisos y de calidad.

Ventajas

- Mejora la eficiencia y la velocidad en el desarrollo y la entrega de proyectos de datos.
- Fomenta la colaboración entre equipos de ciencia de datos, ingeniería de datos y tecnologías de la información (TI).
- Aumenta la calidad y la confiabilidad de los datos mediante la automatización.

Lean Analytics

Lean Analytics es una metodología derivada de **Lean Startup,** que se enfoca en construir soluciones basadas en datos de forma rápida y eficiente. El enfoque está en medir lo que realmente importa para la toma de decisiones, eliminando actividades innecesarias y centrándose en **métricas clave** (Croll *et al.,* 2014).

© Universidad Internacional de La Rioja (UNIR)

Características

- **Medir y aprender:** el ciclo de medición y aprendizaje se enfoca en validar hipótesis rápidamente a través de datos. Los equipos buscan obtener *insights* que conduzcan a decisiones de negocio, iterando de manera constante.
- **Métricas clave:** la identificación de las métricas correctas es esencial en esta metodología, lo que ayuda a guiar las decisiones estratégicas basadas en datos.
- **Rápido prototipado:** se crean versiones mínimas de los modelos y análisis para probar hipótesis y generar resultados rápidos.

Ventajas

- Agilidad en la toma de decisiones basadas en datos.
- Reducción del tiempo de desarrollo mediante la validación rápida de hipótesis.
- Enfoque en métricas relevantes y eliminación de esfuerzos innecesarios.

Six Sigma para Big Data

Six Sigma es una metodología orientada a mejorar la calidad y reducir errores en los procesos empresariales. En Big Data, Six Sigma se puede utilizar para **optimizar la calidad de los datos** y garantizar que los análisis sean precisos y fiables.

© Universidad Internacional de La Rioja (UNIR)

Figura 6. Six Sigma. Fuente: Six Sigma, 2017.

Principios clave

- **Definir, medir, analizar, mejorar y controlar (DMAIC):** estas fases se aplican a los datos para identificar problemas, mejorar la calidad de los datos y optimizar procesos de análisis.
- **Reducción de la variabilidad:** el enfoque está en reducir la variabilidad de los datos y aumentar la precisión de los resultados del análisis.
- **Basado en datos:** todas las decisiones se toman en función de datos medidos y analizados de manera rigurosa.

© Universidad Internacional de La Rioja (UNIR)

Ventajas

- Mejora la calidad y confiabilidad de los datos.
- Ayuda a identificar y eliminar errores en los datos.
- Fomenta un enfoque disciplinado y estadístico para el análisis de datos.

© Universidad Internacional de La Rioja (UNIR)

4.4. Referencias bibliográficas

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide.* Semantic Scholar. https://www.kde.cs.uni-kassel.de/wp-content/uploads/lehre/ws2012-13/kdd/files/CRISPWP-0800.pdf

Croll, A., Yoskovitz, B., Ries, E. y López Manzano, J. (2014). *Lean Analytics: Cómo utilizar los datos para crear más rápido una startup mejor.* Universidad Internacional de La Rioja. https://reunir.unir.net/handle/123456789/4888

Data Science PM. (2024, noviembre 16). *What is SEMMA?* https://www.datascience-pm.com/semma/

Data Science PM. (2025, enero 7). *Kanban for Data Science.* https://www.datascience-pm.com/kanban/

Fayyad, U., Piatetsky-Shapiro, G. y Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine, 17*(3). https://doi.org/10.1609/aimag.v17i3.1230

Fayyad, U., Piatetsky-Shapiro, G. y Smyth, P. (1996). From Data Mining to Knowledge Discovery: An Overview. En Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. y Uthurusamy, R. *Advances in Knowledge Discovery and Data Mining* (p. 1-34). AAAI Press y The MIT Press.

Galán Cortina, V. (2015). *Aplicación de la metodología CRISP-DM a un proyecto de minería de datos en el entorno universitario* [Proyecto de fin de carrera]. Universidad Carlos III de Madrid Escuela Politécnica Superior Ingeniería en Informática. https://e-archivo.uc3m.es/rest/api/core/bitstreams/714c5452-962e-44cf-993f-ebb3088d4aa5/content

© Universidad Internacional de La Rioja (UNIR)

Holdaway, K. (2012). *Predictive Analytics: Development and Deployment of Upstream Data Driven Models.* SPE Latin America and Caribbean Petroleum Engineering Conference, Ciudad de México, México. http://dx.doi.org/10.2118/153454-MS

IPMOGuide. (s. f.). *CRISP-DM, Metodología de Datos.* https://ipmoguide.com/crisp-dm-metodologia-de-datos/

Jurney, R. (2017). *Agile Data Science 2.0: Building Full-Stack Data Analytics Applications with Spark.* O'Reilly Media.

Palmer, A. (2019). *Getting DataOp Right.* O'Reilly Media.

Six Sigma. (2017, julio 7). *Six Sigma y Análisis del Negocio: Análisis Lean Six Sigma.* https://www.sixsigmaespanol.com/six-sigma-articles/six-sigma-y-analisis-del-negocio-analisis-lean-six-sigma/

Yildiz, M. (2021, noviembre 3). *Let's Learn Data Science Jobs You Can Apply. Clarusway* [Infografía]. https://clarusway.com/data-science-jobs-you-can-apply/?srsltid=AfmBOoqWDnuLzLegZ71GeLL7BjuM54aisMnHe0DfxrqwMoQDQaajrx77

© Universidad Internacional de La Rioja (UNIR)

Rol del analista de datos

AddKw. (2024, agosto 5). *Rol del Analista de Datos y Tendencias del Sector* [Vídeo]. YouTube. https://www.youtube.com/watch?v=su4yIjveM7w

El rol del analista de datos es el de proporcionar los insumos a la empresa para la toma de decisiones en todos los niveles. Su papel es fundamental y requiere conocimiento de diversas disciplinas como las matemáticas, la estadística, las bases de datos, la computación, el aprendizaje de máquina, la inteligencia artificial, los servicios en la nube, los procesos de negocios y metodologías, etc.

El analista de datos emplea técnicas de aprendizaje automático, inteligencia artificial y analítica predictiva para identificar patrones ocultos y tendencias en los datos masivos, lo que permite a las empresas optimizar sus operaciones, mejorar las experiencias de los clientes y ser más competitivos.

© Universidad Internacional de La Rioja (UNIR)

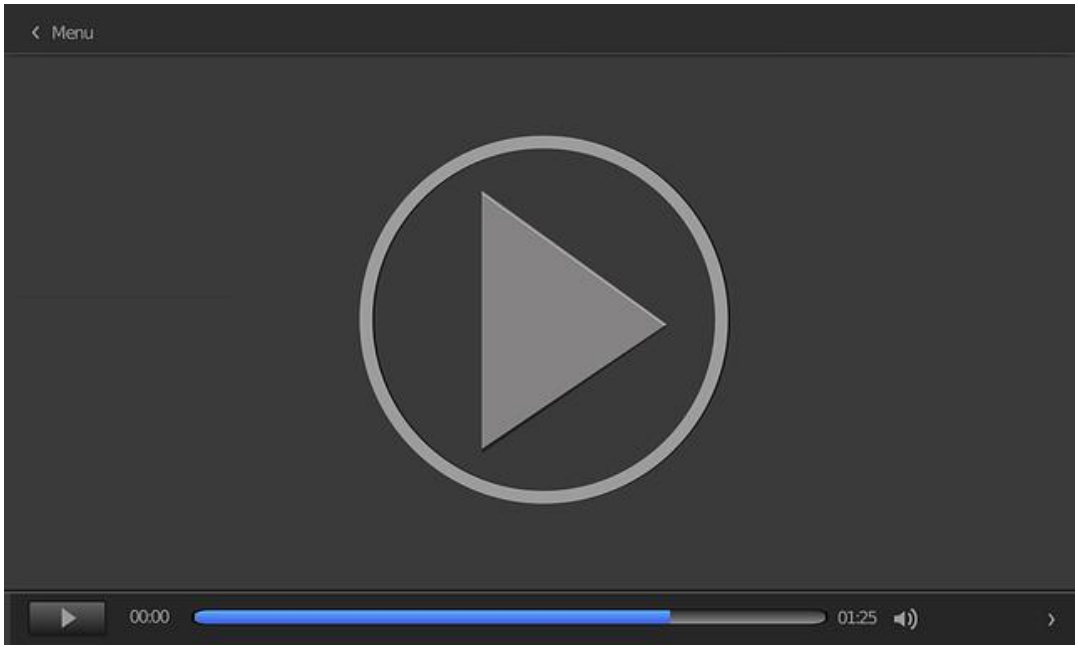

Accede al vídeo:

https://www.youtube.com/embed/su4yIjveM7w

© Universidad Internacional de La Rioja (UNIR)

CRISP-DM, metodología para proyectos de ciencia y minería de datos

AddKw. (2020, mayo 14). *Metodología para proyectos de Data Science y Minería de Datos - CRISP-DM* [Vídeo]. YouTube. https://www.youtube.com/watch?v=E0XTArOciF0

La metodología CRISP-DM (Cross Industry Standard Process for Data Mining) es un estándar ampliamente utilizado en proyectos de ciencia de datos y minería de datos debido a su enfoque práctico y orientado a resultados empresariales. Esta metodología permite planificar, desarrollar y mantener proyectos de diferentes tamaños, garantizando un proceso estructurado y eficaz. CRISP-DM se basa en seis fases interrelacionadas que guían desde la comprensión del negocio hasta la implementación final del modelo.

© Universidad Internacional de La Rioja (UNIR)

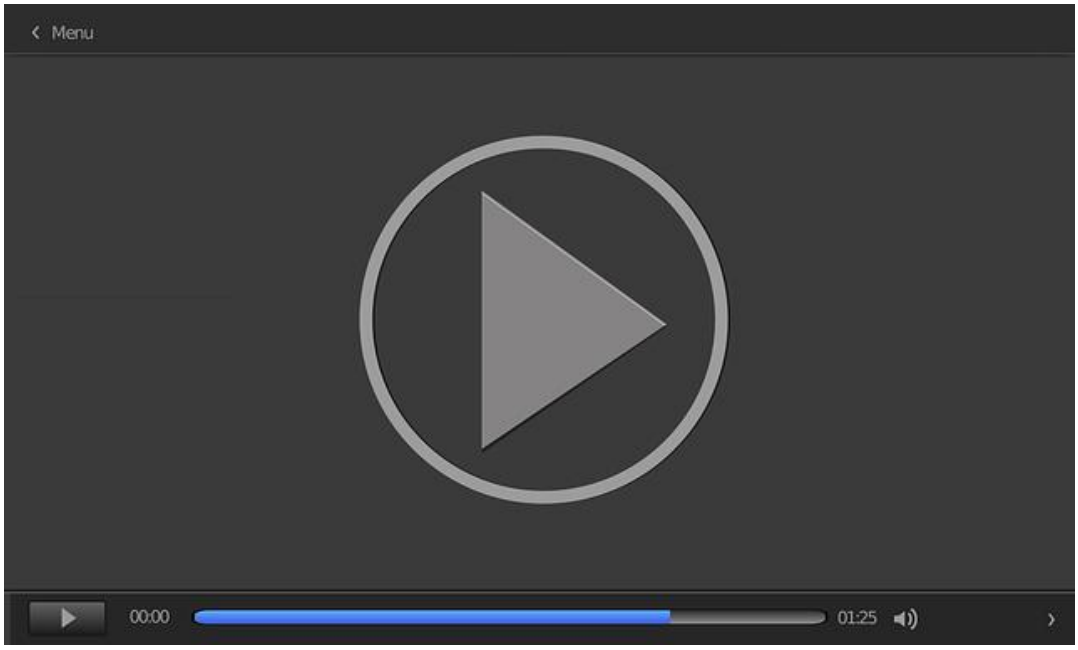

Accede al vídeo:

https://www.youtube.com/embed/E0XTArOciF0

© Universidad Internacional de La Rioja (UNIR)